



ADA RESOURCE LIBRARY

Content Moderation

BEGINNER'S GUIDE

الإشراف على المحتوى

دليل المبتدئين

Accurate Data. Trusted Annotation. Real AI Results.

1. Introduction to Content Moderation at ADA

Welcome to the ADA Content Moderation Beginner Guide. This document introduces the principles, workflow, and quality standards that every ADA content moderator follows when reviewing data for AI training and platform safety projects.

Content moderation sits at the intersection of human judgment and machine learning: the labels you apply directly shape how AI systems recognize and respond to harmful, sensitive, or policy-violating content. At ADA, we believe accurate, consistent, and well-documented moderation decisions are what separate trustworthy AI training data from unreliable data.

This guide walks you through what content moderation is, the categories of content you will encounter, the step-by-step review process, and the quality standards ADA expects from every moderator.

2. What Is Content Moderation?

Content moderation is the process of reviewing content — text, images, audio, or video — against a defined set of policy guidelines and applying the correct label, flag, or action.

Unlike straightforward annotation tasks such as part-of-speech tagging, content moderation requires contextual judgment: the same word or image can be acceptable in one context and a violation in another.

In the AI industry, content moderation data is used to train and evaluate models that detect hate speech, misinformation, graphic violence, spam, and other harmful categories before that content ever reaches real users. Every decision a moderator makes becomes a training signal, so precision and consistency matter as much as speed.

3. General Moderator Rules

Every ADA moderator follows these baseline rules on every project, regardless of client or category:

- Apply the official guideline document, not personal opinion, every time a decision is made.
- Stay consistent: identical or near-identical content should always receive the same label.
- Read full context before deciding; a sentence, image, or clip can change meaning entirely depending on the surrounding material.
- When a case feels ambiguous, escalate it. Guessing is never acceptable.
- Document the reasoning behind every flagged or escalated decision in the notes field.

- Protect your own wellbeing. Sensitive material can be emotionally taxing; ADA encourages scheduled breaks and supports moderators who need to step away from difficult content.
- Treat every file as confidential. Content reviewed during a project must never be shared, discussed outside the project, or saved locally.

4. Content Moderation Categories

ADA moderators typically work across the following policy categories. Each client project provides its own detailed guideline document, but the categories below represent the industry-standard starting point:

- Hate Speech & Discrimination — content that attacks, demeans, or incites hostility against a person or group based on protected characteristics such as race, religion, gender, nationality, or disability.
- Violence & Graphic Content — depictions or descriptions of real-world violence, including content that glorifies, threatens, or incites physical harm.
- Sexual & Adult Content — material that is sexually explicit or inappropriate for general audiences. Any content involving minors must be escalated immediately rather than labeled.
- Harassment & Bullying — targeted attacks, threats, or demeaning content directed at a specific individual or group.
- Spam & Misleading Content — deceptive, manipulative, or repetitive content designed to mislead users or game a platform's systems.
- Misinformation & Disinformation — false or misleading claims presented as fact, particularly around health, elections, or public safety.
- Self-Harm & Dangerous Behavior — content that promotes, instructs, or glorifies self-harm, suicide, or other dangerous activities.
- Illegal Activity & Regulated Goods — content facilitating illegal transactions, regulated substances, or other unlawful activity.

Important: any content suggesting imminent risk to a real person's safety (self-harm, threats of violence, child exploitation) must be escalated immediately through the emergency escalation path defined in your project guidelines — not simply labeled and left in queue.

5. Step-by-Step Moderation Process

1. Receive the content item along with any available context (platform, surrounding conversation, metadata).
2. Review the item against the current version of the client's policy guideline document — guidelines are updated frequently, so always confirm you are working from the latest version.

3. Identify the applicable category or categories.
4. Determine the correct action: approve, flag for review, label by category, or escalate.
5. Record a short, clear rationale explaining the decision.
6. Submit the item for the next stage of the workflow, which typically includes a QA review pass.

6. Severity Levels & Escalation

Most ADA projects use a four-tier severity scale:

- Low — minor policy friction with no real-world harm risk (e.g. mild rule-breaking).
- Medium — clear policy violation requiring action but no urgent safety risk.
- High — violation with potential for real harm, requiring prompt review by a senior moderator.
- Critical — immediate risk to a person's safety or wellbeing (self-harm, credible threats, child safety). Critical cases must be escalated immediately through the designated emergency path — never delayed for batch review.

When in doubt about severity, always escalate to the next tier up rather than down.

7. Common Mistakes & How to Avoid Them

- Applying personal beliefs instead of the official guideline — always default to the written policy, even when you personally disagree with it.
- Skipping context — reviewing content in isolation, without checking surrounding conversation or metadata, is the leading cause of mislabeling.
- Over-flagging or under-flagging — both reduce data quality. Calibration sessions exist specifically to correct this drift.
- Inconsistency across similar items — keep a mental or written log of edge cases you've seen before, and apply the same logic each time.
- Leaving the rationale field blank — QA reviewers and clients rely on your documented reasoning to audit decisions and refine guidelines.

8. Quality Expectations & Review Criteria

ADA holds every content moderation project to the following standards:

- Accuracy — moderators are expected to maintain at least 95% agreement with QA reviewers and the gold-standard answer set.

- Consistency — repeated or near-duplicate items must receive matching labels across the full dataset.
- Documentation — every flagged, escalated, or rejected item must include a clear, written rationale.
- Turnaround — moderators are expected to meet the throughput targets set for each project while never sacrificing accuracy for speed.
- Calibration — moderators participate in regular calibration sessions where sample decisions are reviewed against the gold standard to identify and correct any drift.

Moderators who fall below quality thresholds receive additional guideline review and coaching before returning to live project work — ADA's goal is always to build skill, not simply to flag underperformance.



Arabic Translation

الترجمة العربية

1. مقدمة عن الإشراف على المحتوى في ADA

مرحبا بكم في دليل المبتدئين للإشراف على المحتوى من شركة ADA. يقدم هذا المستند المبادئ وسير العمل ومعايير الجودة التي يتبناها كل مشرف محتوى في ADA. عند مراجعة البيانات لمشاريع تدريب الذكاء الاصطناعي وسلامة المنصات ADA يقع الإشراف على المحتوى عند تقاطع الحكم البشري والتعلم الآلي: فالتصنيفات التي تطبقها تشكل مباشرة كيفية تعرف أنظمة الذكاء الاصطناعي على المحتوى الضار أو الحساس أو المخالف للسياسات والاستجابة له. في ADA، نؤمن بأن قرارات الإشراف الدقيقة والمتسقة والموثقة جيدا هي ما يميز بيانات تدريب الذكاء الاصطناعي الموثوقة عن البيانات غير الموثوقة.

سيرشدك هذا الدليل عبر تعريف الإشراف على المحتوى، وفئات المحتوى التي ستواجهها، وعملية المراجعة خطوة بخطوة، ومعايير الجودة التي تتوقعها ADA من كل مشرف.

2. ما هو الإشراف على المحتوى؟

الإشراف على المحتوى هو عملية مراجعة المحتوى – نصا كان أو صورة أو صوتا أو فيديو – وفق مجموعة محددة من إرشادات السياسة، ثم تطبيق التصنيف أو العلامة أو الإجراء الصحيح.

وعلى عكس مهام التوسيم المباشرة مثل تصنيف أجزاء الكلام، يتطلب الإشراف على المحتوى حكما سياقيا: فقد تكون الكلمة أو الصورة نفسها مقبولة في سياق معين ومخالفة في سياق آخر.

في صناعة الذكاء الاصطناعي، تستخدم بيانات الإشراف على المحتوى لتدريب وتقييم النماذج التي تكتشف خطاب الكراهية والمعلومات المضللة والعنف الصريح والرسائل المزعجة وغيرها من الفئات الضارة قبل وصول هذا المحتوى إلى المستخدمين الفعليين. كل قرار يتخذه المشرف يصبح إشارة تدريب، لذلك تعد الدقة والاتساق بنفس أهمية السرعة.

3. القواعد العامة للمشرف

يلتزم كل مشرف في ADA بالقواعد الأساسية التالية في كل مشروع، بغض النظر عن العميل أو الفئة:

- طبق وثيقة الإرشادات الرسمية، لا الرأي الشخصي، في كل قرار تتخذه.
- حافظ على الاتساق: يجب أن يحصل المحتوى المتطابق أو شبه المتطابق دائماً على نفس التصنيف.
- اقرأ السياق الكامل قبل اتخاذ القرار؛ فالجملة أو الصورة أو المقطع قد يتغير معناه كلياً حسب المادة المحيطة به.
- عند الشعور بالغموض في الحالة، قم بتصعيدها. التخمين غير مقبول إطلاقاً.
- وثق سبب أي قرار تصعيد أو تصنيف في حقل الملاحظات.
- احم صحتك النفسية: قد تكون المواد الحساسة مرهقة عاطفياً؛ تشجع ADA على أخذ فترات راحة منتظمة وتدعم المشرفين الذين يحتاجون إلى الابتعاد عن المحتوى الصعب.
- تعامل مع كل ملف على أنه سري تماماً. يجب ألا تتم مشاركة المحتوى الذي تتم مراجعته أثناء المشروع أو مناقشته خارج نطاقه أو حفظه محلياً.

4. فئات الإشراف على المحتوى

يعمل مشرفو ADA عادة ضمن فئات السياسة التالية. يوفر كل مشروع عميل وثيقة إرشادات تفصيلية خاصة به، لكن الفئات أدناه تمثل نقطة البداية المعتمدة في الصناعة:

- خطاب الكراهية والتمييز — محتوى يهاجم أو يحط من قدر أو يحرض على العداء تجاه شخص أو مجموعة بناء على خصائص محمية مثل العرق أو الدين أو الجنس أو الجنسية أو الإعاقة.
- العنف والمحتوى الصريح — تصوير أو وصف لعنف واقعي، بما في ذلك المحتوى الذي يمجّد العنف الجسدي أو يهدد به أو يحرض عليه.
- المحتوى الجنسي ومحتوى البالغين — مواد ذات طابع جنسي صريح أو غير مناسبة للجمهور العام. يجب تصعيد أي محتوى يتعلق بالقاصرين فوراً دون تصنيفه.
- التحرش والتنمر — هجمات أو تهديدات أو محتوى مهين موجه إلى شخص أو مجموعة محددة.

- الرسائل المزعجة والمحتوى المضلل — محتوى خادع أو متلاعب أو متكرر مصمم لتضليل المستخدمين أو التحايل على أنظمة المنصة.
- المعلومات المضللة والتضليل الإعلامي — ادعاءات كاذبة أو مضللة تقدم كحقائق، خاصة فيما يتعلق بالصحة أو الانتخابات أو السلامة العامة.
- إيذاء النفس والسلوك الخطير — محتوى يروج أو يوجه أو يمجّد إيذاء النفس أو الانتحار أو غيره من الأنشطة الخطيرة.
- النشاط غير القانوني والسلع الخاضعة للرقابة — محتوى يسهل معاملات غير قانونية أو مواد خاضعة للرقابة أو أي نشاط آخر مخالف للقانون.
- مهم: أي محتوى يشير إلى خطر وشيك على سلامة شخص حقيقي (إيذاء النفس، تهديدات بالعنف، استغلال الأطفال) يجب تصعيده فوراً عبر مسار التصعيد الطارئ المحدد في إرشادات مشروعك، وليس مجرد تصنيفه وتركه في قائمة الانتظار.

5. عملية الإشراف خطوة بخطوة

1. استلم عنصر المحتوى مع أي سياق متاح (المنصة، المحادثة المحيطة، البيانات الوصفية).
2. راجع العنصر وفق النسخة الحالية من وثيقة إرشادات سياسة العميل — يتم تحديث الإرشادات بشكل متكرر، لذا تأكد دائماً من أنك تعمل بأحدث نسخة.
3. حدد الفئة أو الفئات المنطبقة.
4. حدد الإجراء الصحيح: الموافقة، التصنيف للمراجعة، التصنيف حسب الفئة، أو التصعيد.
5. سجل تبريراً موجزاً وواضحاً يشرح القرار.
6. أرسل العنصر إلى المرحلة التالية من سير العمل، والتي تتضمن عادة مراجعة ضمان الجودة.

6. مستويات الخطورة والتصعيد

- تستخدم معظم مشاريع ADA مقياس خطورة من أربع مستويات:
- منخفض — مخالفة بسيطة للسياسة دون خطر فعلي على السلامة (مثل مخالفة طفيفة للقواعد).

- متوسط — مخالفة واضحة للسياسة تتطلب إجراء دون وجود خطر سلامة عاجل.
- مرتفع — مخالفة تحمل احتمال ضرر حقيقي، وتتطلب مراجعة سريعة من مشرف أول.
- حرج — خطر مباشر على سلامة شخص أو صحته النفسية (إيذاء النفس، تهديدات موثوقة، سلامة الأطفال). يجب تصعيد الحالات الحرجة فوراً عبر مسار الطوارئ المخصص — ولا يجوز تأجيلها للمراجعة الدفعية.
- عند الشك في مستوى الخطورة، قم دائماً بالتصعيد إلى المستوى الأعلى وليس الأدنى.

7. الأخطاء الشائعة وكيفية تجنبها

- تطبيق المعتقدات الشخصية بدلاً من الإرشاد الرسمي — التزم دائماً بالسياسة المكتوبة، حتى عند اختلافك الشخصي معها.
- تجاهل السياق — مراجعة المحتوى بمعزل عن المحادثة المحيطة أو البيانات الوصفية هو السبب الرئيسي للتصنيف الخاطئ.
- الإفراط في التصنيف أو التقصير فيه — كلاهما يقلل من جودة البيانات. جلسات المعايرة موجودة خصيصاً لتصحيح هذا الانحراف.
- عدم الاتساق بين العناصر المتشابهة — احتفظ بسجل ذهني أو مكتوب للحالات الاستثنائية التي واجهتها سابقاً، وطبق المنطق نفسه في كل مرة.
- ترك حقل التبرير فارغاً — يعتمد مراجعو ضمان الجودة والعملاء على تبريرك الموثق لمراجعة القرارات وتحسين الإرشادات.

8. توقعات الجودة ومعايير المراجعة

تلتزم ADA بالمعايير التالية في كل مشروع إشراف على المحتوى:

- الدقة — يتوقع من المشرفين الحفاظ على نسبة اتفاق لا تقل عن 95٪ مع مراجعي ضمان الجودة ومجموعة الإجابات المعتمدة.
- الاتساق — يجب أن تحصل العناصر المتكررة أو شبه المتطابقة على تصنيفات متطابقة عبر مجموعة البيانات بأكملها.
- التوثيق — يجب أن يتضمن كل عنصر مصنف أو مصعد أو مرفوض تبريراً واضحاً ومكتوباً.

- سرعة الإنجاز – يتوقع من المشرفين تحقيق أهداف الإنتاجية المحددة لكل مشروع دون التضحية بالدقة مقابل السرعة.

- المعايرة – يشارك المشرفون في جلسات معايرة منتظمة تتم فيها مراجعة عينات من القرارات مقابل المعيار المعتمد لتحديد أي انحراف وتصحيحه.

يحصل المشرفون الذين تقل جودتهم عن الحد الأدنى المطلوب على مراجعة إضافية للإرشادات وتدريب توجيهي قبل العودة إلى العمل الفعلي في المشروع – هدف ADA دائما هو بناء المهارة، وليس مجرد الإشارة إلى ضعف الأداء.