



ACCURATE DATA ANNOTATOR

LLM EVALUATION & RLHF MANUAL

دليل تقييم النماذج اللغوية والتعلم المعزز البشري

Resource Library Asset: ADA-RLHF-MIRROR

High-Value Tier Specialization

ENGLISH / العربية

1. CORE METRICS: THE 3 HS OF LLM ALIGNMENT

Reinforcement Learning from Human Feedback (RLHF) shifts basic annotators into evaluative judges. Instead of creating simple tags, specialists rate side-by-side model predictions based on the 3 Hs framework:

- **Truthfulness:** Total freedom from logical contradictions, hallucinations, or obsolete fabrications.
- **Helpfulness:** Following the prompt intent cleanly, using rich structuring, and fulfilling parameters.
- **Harmlessness:** Active avoidance of toxic programming, dangerous recipes, or systemic bias.

1. المقاييس الأساسية: الـ HS 3 لمواءمة النماذج اللغوية

ينقل التعلم المعزز من ردود الفعل البشرية (RLHF) المرمّزين الأساسيين إلى مرتبة القضاة المقيمين. بدلاً من إنشاء تسميات بسيطة، يقوم المتخصصون بتقييم تنبؤات النماذج جنباً إلى جنب بناءً على إطار عمل الـ HS 3:

- **المصداقية (Truthfulness):** الخلو التام من التناقضات المنطقية، أو الهلوسة، أو الفبركات البرمجية.
- **الفائدة (Helpfulness):** اتباع نية وهدف الأمر البرمجي بوضوح، مع استخدام هيكلية غنية وتلبية المعايير المطلوبة.
- **الأمان والمسالمة (Harmlessness):** التجنب النشط للألفاظ السامة، أو الوصفات الخطرة، أو التحيزات المنهجية.

2. FORMULATING ENGINEERING JUSTIFICATIONS

Premium platforms require human evaluators to provide detailed analytical written statements explaining exactly **why** Model A outperformed Model B.

Gold Standard Justification Blueprint

"Model A is significantly preferred over Model B due to clear adherence to structural limitations and absolute Truthfulness. While the prompt requested a maximum of two paragraphs, Model B generated four paragraphs and introduced a clear logical hallucination in sentence 3 regarding state hooks. Conversely, Model A followed formatting specifications and remained factually verified."

2. صياغة التبريرات والتقارير التحليلية

تتطلب المنصات المتقدمة ذات الأجور المرتفعة من المقيمين البشريين تقديم بيانات مكتوبة تحليلية ومفصلة تشرح بدقة لماذا* تفوق النموذج (أ) على النموذج (ب).

المخطط النموذجي للتبرير الاحترافي

"يُفضل النموذج (أ) بشكل كبير على النموذج (ب) نظراً للالتزام الواضح بالقيود الهيكلية والمصادقية المطلقة. في حين طلب الأمر بحد أقصى فقرتين، قام النموذج (ب) بتوليد أربع فقرات وأدخل هلوسة منطقية واضحة في الجملة الثالثة المتعلقة بخطافات الحالة (State Hooks). وعلى العكس من ذلك، اتبع النموذج (أ) مواصفات التنسيق وظل موثقاً من حيث الحقائق."